

面向未见相机配置的时空几何精化射线提升

Temporal Geometry-Refined Ray Lifting for Camera-Generalizable Multi-view 3D Human Pose Estimation

Anonymous CVPR submission

Paper ID 0000

实验数据待补全的研究稿：所有结果单元均以“—”占位，本文不包含任何虚构实验数值。

Abstract

多视角三维人体姿态估计在固定相机系统上已取得较高精度，但其性能往往隐式依赖训练时的相机数量、空间布局与二维检测误差分布。当视角数量、相机外参或遮挡模式发生变化时，纯学习式融合容易把训练场景的偶然相关性当作稳定几何规律；另一方面，解析三角化虽然天然适配新相机，却对二维关键点噪声、小基线和长时遮挡极为敏感。本文提出 *TGR-Ray*，一种面向未见相机配置的时空几何射线提升框架。核心思想是：让网络学习难以精确建模的检测噪声、运动先验与观测不确定性，而将可精确描述的相机几何交给可微解析求解器。具体而言，我们首先把每个二维关键点转为世界坐标射线，并以射线间距离、三角化夹角和检测置信度构造跨视角注意力偏置；随后沿同一关节的时间轨迹建模运动上下文，在射线切平面内预测受限角度修正与异方差不确定性；最终通过不确定性加权的闭式射线求交，将粗姿态先验与修正后的几何观测统一到一个可微最小二乘问题中。训练阶段进一步随机化相机环境、视角数量、关节缺失和连续遮挡，以抑制对固定采集系统的依赖。本文给出 *Human3.6M*、*TotalCapture* 与跨数据集评测的完整实验协议、鲁棒性测试及消融设计；数值结果将在完成统一二维检测器下的真实训练后填写。

1. 引言

由多个同步相机恢复人体三维关节，是动作分析、虚拟现实、体育训练和人机交互的基础能力。与单目估计相比，多视角观测能够通过视差显著缓解深度歧义。然而，现有高精度方法通常在同一套相机上训练和测试：相机编号、视角数量、空间基线乃至二维检测器的错误模式在训练期间几乎不变。模型因此可能学到“某个输入槽位对应某个方向”“某对相机总能形成稳定基线”等捷径。部署到未见方位、不同数量或局部失效的相机后，这些捷径不再成立，域内精度便不能代表真实泛化能力 [1, 2, 13]。

这一问题形成了一个长期存在的张力。解析三角化显式使用投影几何，对相机排列没有可学习参数，理论上能够直接迁移；但二维关键点存在误检、遮挡和置信度失准时，多条射线不严格相交，近共线相机还会放大深度误差。相反，端到端回归能够从数据中学习人体结构与遮挡先验，却容易把有限的训练相机编码进网络。近期研究从随机假设、概率相机、几何约束或多环境训练等角度改善泛化 [1, 2, 9, 14]，但三个问题仍未被同时解决：

1. **几何可靠性没有被充分用于跨视角融合。**同一关节的两条射线是否相容、三角化夹角是否稳定，是由相机和观测共同决定的连续量，不应仅由数据驱动注意力隐式猜测。
2. **二维误差具有时间结构。**单帧误检、连续遮挡和低频偏移的统计性质不同。仅在单帧内融合多视角，会丢失相邻帧中可用于判别异常射线的冗余证据。

3. **粗回归与几何求交缺少统一出口**。若网络直接回归最终坐标，几何约束可能被绕过；若只做硬三角化，又无法利用人体与运动先验处理退化配置。

本文据此提出 TGR-Ray。与把更多通用块堆叠到姿态回归器中的思路不同，TGR-Ray 重新划分学习与解析计算的职责。模型以世界射线作为相机无关的基本表示，在跨视角注意力中显式注入射线距离、三角化角和二维置信度；沿每个关节的时间轴独立聚合上下文，避免先把所有关节和帧混成一个难以解释的全局令牌集合；随后只在射线切平面内预测小幅残差以及对应的不确定性，不改变相机中心；最终以闭式加权最小二乘求解三维关节，并用粗姿态作为退化情况下的软锚点。这个设计使相机相关的深度恢复仍由投影几何完成，而网络主要负责识别“哪条射线可信、需要修正多少”。

图 1 给出了整体框架。训练时随机采样合成相机环境，同时对真实二维检测施加视角丢弃、关节丢弃和连续遮挡。测试时不需要相机编号嵌入，输入视角可以任意排列，视角数量可在训练范围内变化。

本文的主要贡献可概括为：

- 提出一种面向未见相机配置的混合式射线提升框架，将可学习的噪声/运动建模与解析相机几何分离，避免最终三维坐标完全依赖训练相机分布。
- 提出几何-置信度偏置的跨视角融合，并引入逐关节时序上下文，在可变视角、低基线和连续遮挡下为射线可靠性提供显式依据。
- 提出切平面残差与异方差联合预测，以及带粗姿态软锚点的可微闭式求解器，使学习先验不能绕过射线几何，同时保留对退化观测的鲁棒性。
- 建立区分域内精度、未见相机泛化、二维噪声鲁棒性与时间稳定性的评测协议，并预定义完整消融和效率报告格式，避免只在单一固定相机划分上得出泛化结论。

2. 相关工作

2.1. 多视角三维人体姿态估计

解析几何路线。经典流水线先由单视角检测器获得二维关键点，再利用已标定相机进行线性或非线性的三角化。可学习三角化将体素特征或关节热图与相机

投影结合，在标准数据集上显著提高精度 [8]；极线特征变换则在图像层沿极线交换跨视角证据 [6]。这类方法的优势是几何可解释，但二维异常值、遮挡和小三角化夹角会造成病态求解。随机假设评分通过从视角子集生成候选姿态，再学习与相机布局无关的候选质量，在新相机排列上表现出更稳定的迁移 [1]。概率三角化进一步联合建模姿态和相机不确定性，使未标定或弱标定场景下的推断更稳健 [9]。

学习式融合路线。另一类方法直接融合多视角二维骨架或图像特征。自注意力能够接收可变数量的令牌，因而适合描述视角之间的长程关系。MTF-Transformer 将多视角融合和时间融合统一到注意力框架中 [15]；几何偏置注意力利用极线距离与检测分数调节跨视角信息交换 [14]。面向多人场景的几何-外观交替推理表明，把视角相关的三维操作保留为无学习几何模块，有助于新相机和新布局迁移 [13]。然而，若最终坐标仍由自由回归头输出，模型仍可能通过人体或相机先验规避显式几何。

射线提升提供了二者之间的中间表示：二维观测和相机标定共同定义世界空间射线，而射线本身不带固定相机编号。MPL 通过合成投影将单目动作库转为多视角监督 [4]；RUMPL 进一步以射线和置信度为输入，在视角与关节维度进行分解式融合，实现对相机数量和布局的迁移 [5]。本文以这一观察为起点，但认为仅让 Transformer 隐式学习射线相容性仍不充分。我们把连续几何条件写入注意力，并让最终输出回到显式射线求交。

2.2. 相机泛化与环境随机化

相机泛化至少包含三种变化：同一场景中的视角数量变化、相机外参/内参构成的未见配置，以及动作、二维检测器和图像域共同变化的跨数据集迁移。这三者不应混为一个指标。只随机丢弃视角能够缓解数量变化，却不能保证模型适配新的方位和焦距；在合成相机上训练若与测试相机空间重叠，又会高估配置泛化。

通过大量合成相机扩展二维-三维姿态对是一条直接路径。PoseIRM 把不同相机设置视为多个训练环境，并约束模型学习跨环境稳定的预测规律 [2]。离散二维-三维先验也可通过统一码本降低特定相机连续坐标对模型的束缚 [3]。这些结果说明，相机分布本身应成为实验变量，而不是数据集附带的固定常数。本文因此在




图 1. **TGR-Ray 总体框架**。蓝色表示可学习表征，青色表示解析几何，橙色表示射线修正与不确定性。二维关键点首先被转换为世界射线；跨视角分支融合射线相容性与检测可信度，同关节时序分支提供运动上下文。模型在切平面内预测受限射线残差，并估计每条观测的方差；修正射线与粗姿态共同进入闭式求解器得到最终三维姿态。训练时才启用相机环境随机化和遮挡增强。

训练阶段显式采样相机环境，并在测试阶段保留互斥的方位、俯仰和焦距区间；同时报告域内误差、域外误差及二者差值。与依赖相机 ID 的位置编码不同，我们只使用由标定参数计算的连续几何量，保证视角置换不改变预测。

2.3. 时序姿态与不确定性建模

视频中的人体运动提供强冗余。PoseFormer、MHFormer 与 MixSTE 等工作表明，注意力能够在较长序列中建模关节轨迹和多解分布 [12, 17, 18]。其中，按关节分离的时间编码避免不同关节的动态模式在早期被混合，且序列到序列监督有助于输出连续性。多视角任务中的时间信息还有额外作用：它不仅平滑三维结果，更能判断某条二维射线是短时抖动、持续偏移还是连续遮挡。因此，本文把时序分支放在视角融合之后、全身姿态融合之前，并把其输出用于调节射线修正与观测方差。

不确定性为软融合不同质量的观测提供了统一语言。异方差回归通过同时预测残差和对数方差，使高

噪声样本不会被迫与清晰样本等权 [11]。在多视角任务中，不确定性应与几何条件共同决定权重：高置信度二维点在近共线相机下仍可能产生不可靠深度，低置信度点也可能因多视角一致而可用。本文因此不直接把检测分数当作最终权重，而是将其与射线夹角、跨视角相容性和时序上下文联合校准。

3. 方法

3.1. 问题定义与世界射线表示

给定长度为 T 的同步序列、 V 个已标定相机和 J 个身体关节，二维检测器输出 $\mathcal{X} = \{(\mathbf{x}_{t,v,j}, c_{t,v,j})\}$ ，其中 $\mathbf{x}_{t,v,j} = (u, v)^\top$ ， $c_{t,v,j} \in [0, 1]$ 。相机内参、旋转和平移分别记为 $\mathbf{K}_v, \mathbf{R}_v, \mathbf{t}_v$ 。相机中心和单位世界射线方向为

$$\mathbf{o}_v = -\mathbf{R}_v^\top \mathbf{t}_v, \quad \mathbf{d}_{t,v,j} = \text{normalize}(\mathbf{R}_v^\top \mathbf{K}_v^{-1} \tilde{\mathbf{x}}_{t,v,j}), \quad (1)$$

其中 $\tilde{\mathbf{x}} = (u, v, 1)^\top$ 。于是每个观测对应 $\ell_{t,v,j}(s) = \mathbf{o}_v + s\mathbf{d}_{t,v,j}$ 。模型输入令牌由射线方向、相机中心的场

景中心化坐标、二维置信度及缺失掩码经过共享 MLP 得到。所有相机共享参数，不加入相机编号或固定视角位置嵌入。

3.2. 几何--置信度偏置的跨视角融合

对固定的 (t, j) ，我们只在视角维度做自注意力。两条世界射线的最短距离为

$$D_{vu} = \frac{|(\mathbf{o}_u - \mathbf{o}_v)^\top (\mathbf{d}_v \times \mathbf{d}_u)|}{\|\mathbf{d}_v \times \mathbf{d}_u\|_2 + \epsilon}, \quad (2)$$

三角化条件由夹角可靠性

$$S_{vu} = 1 - (\mathbf{d}_v^\top \mathbf{d}_u)^2 \quad (3)$$

描述。 D_{vu} 小表示两条射线在三维中相容， S_{vu} 大表示基线对深度更敏感。第 h 个注意力头的分数写为

$$\begin{aligned} a_{vu}^{(h)} &= \frac{(\mathbf{q}_v^{(h)})^\top \mathbf{k}_u^{(h)}}{\sqrt{d_h}} - \alpha_h \log\left(1 + \frac{D_{vu}}{\tau_D}\right) \\ &\quad + \gamma_h \log(S_{vu} + \epsilon) + \beta_h \log(c_v c_u + \epsilon), \quad (4) \\ A_{vu}^{(h)} &= \text{softmax}_u(a_{vu}^{(h)}). \quad (5) \end{aligned}$$

其中 $\alpha_h, \gamma_h, \beta_h \geq 0$ 由 softplus 参数化，允许不同头分别关注外观/姿态先验、几何相容性和检测质量。缺失观测通过掩码在 softmax 前置为 $-\infty$ 。由于式 (2)-(4) 只依赖两两关系且所有视角共享映射，模块对输入视角置换等变；随后以置信度门控池化得到每个关节的融合令牌 $\mathbf{z}_{t,j}$ ，因此对输出置换不变。

训练初期，随机初始化的二维特征尚未形成稳定语义，过强几何偏置可能导致注意力塌缩。我们使用前 E_w 个 epoch 的线性暖启动系数 $\eta \in [0, 1]$ 同时缩放三个偏置项；并对 D_{vu} 采用分位数裁剪，避免严重误检产生极端梯度。

3.3. 逐关节时序上下文

视角融合后得到 $\mathbf{Z} \in \mathbb{R}^{B \times T \times J \times d}$ 。我们将其重排为 $(BJ) \times T \times d$ ，使同一关节只沿时间轴交换信息：

$$\hat{\mathbf{Z}}_j = \text{TempEnc}(\mathbf{Z}_j + \mathbf{E}_{\Delta t}^{\text{el}}). \quad (6)$$

相对时间编码使测试窗口可在训练长度附近变化，也避免把绝对帧号当作语义。与直接对 TJ 个令牌做全局注意力相比，该分解降低了计算量，并保留“哪一个关节的轨迹支持当前观测”的可解释性。




图 2. 受限射线精化与解析求交。模型只在射线切平面内预测小角度残差，并以不确定性权重进入闭式求解；相机中心保持不变。

随后，在每一帧内对 J 个关节执行姿态融合，学习骨长、左右对称和关节协同，输出粗姿态 $\mathbf{Q}_{0,t} \in \mathbb{R}^{J \times 3}$ 。时序模块预测整个窗口，训练时对所有帧监督；评测可根据协议输出中心帧或最新帧。这里的粗姿态并非最终结果，而是在视角退化或仅剩少量有效射线时为解析求解提供软先验。

3.4. 切平面射线修正与异方差

直接预测新的三维射线方向会引入三个自由度，并可能通过改变相机中心绕过成像约束。我们固定 $\mathbf{o}_v$ ，在单位射线 $\mathbf{d}_{t,v,j}$ 的切平面上构造正交基 $\mathbf{e}_1, \mathbf{e}_2 \perp \mathbf{d}$ 。由每视角上下文、时序上下文和置信度共同预测 $(\Delta\theta_1, \Delta\theta_2, s)$ ，其中 $s = \log \sigma^2$ ：

$$\mathbf{d}' = \text{normalize}(\mathbf{d} + \Delta\theta_1 \mathbf{e}_1 + \Delta\theta_2 \mathbf{e}_2). \quad (7)$$

利用 $\Delta\theta_k = \theta_{\max} \tanh(r_k)$ 限制最大修正角，初始取 $\theta_{\max} = 5^\circ$ 。这种残差参数化保留原始二维观测的可解释性，也使“未修正射线”成为易优化的恒等初值。

每视角上下文首先产生角度修正；逐关节时序上下文再对连续帧的 s 和修正幅度进行校准。这样，孤立抖动可被降权，连续遮挡不会因简单时间平滑而被错误传播。观测的最终非负权重为

$$w_{t,v,j} = \tilde{c}_{t,v,j} \exp(-s_{t,v,j}), \quad \tilde{c} = \text{calib}(c, D, S), \quad (8)$$

其中 calib 是小型共享标定头。为避免所有方差同时增大导致退化，训练目标中包含对数方差项，并将 s 裁剪到预设区间。

3.5. 不确定性加权的闭式射线求解

对单位方向 $\mathbf{d}'_v$ ，令

$$\mathbf{P}_v = \mathbf{I} - \mathbf{d}'_v (\mathbf{d}'_v)^\top \quad (9)$$

为到射线法平面的投影矩阵。最终关节位置通过

$$\mathbf{q}^* = \arg \min_{\mathbf{q}} \sum_{v=1}^V w_v \|\mathbf{P}_v(\mathbf{q} - \mathbf{o}_v)\|_2^2 + \lambda \|\mathbf{q} - \mathbf{q}_0\|_2^2 \quad (10)$$

获得。令

$$\mathbf{A} = \sum_v w_v \mathbf{P}_v + \lambda \mathbf{I}, \quad \mathbf{b} = \sum_v w_v \mathbf{P}_v \mathbf{o}_v + \lambda \mathbf{q}_0, \quad (11)$$

则

$$\mathbf{q}^* = \mathbf{A}^{-1} \mathbf{b}. \quad (12)$$

实现中不显式求逆，而使用带 Cholesky 失败回退的线性方程求解。 λ 可由有效视角数和 $\mathbf{A}$ 的条件数自适应调节：几何充分时让射线主导，退化时提高粗姿态软锚点。式 (12) 对 $\mathbf{d}', w, \mathbf{q}_0$ 可微，因此上游网络能够从最终三维误差端到端学习，但无法跳过相机几何直接输出任意坐标。

3.6. 训练目标

总损失为

$$\mathcal{L} = \mathcal{L}_{\text{final}} + \lambda_0 \mathcal{L}_{\text{coarse}} + \lambda_\theta \mathcal{L}_{\text{angle}} + \lambda_r \mathcal{L}_{\text{ray}} + \lambda_v \mathcal{L}_{\text{vel}}. \quad (13)$$

$\mathcal{L}_{\text{final}}$ 与 $\mathcal{L}_{\text{coarse}}$ 分别监督最终和粗三维关节，可采用平滑 L_1 。若真值关节为 $\mathbf{q}^{gt}$ ，目标射线 $\mathbf{d}^{gt} = \text{normalize}(\mathbf{q}^{gt} - \mathbf{o})$ ，则 $\mathcal{L}_{\text{angle}} = 1 - (\mathbf{d}')^\top \mathbf{d}^{gt}$ 。异方差射线误差为

$$e_{\text{ray}} = \|(\mathbf{I} - \mathbf{d}'(\mathbf{d}')^\top)(\mathbf{q}^{gt} - \mathbf{o})\|_2^2, \quad \mathcal{L}_{\text{ray}} = \exp(-s)e_{\text{ray}} + s. \quad (14)$$

速度项约束相邻帧三维位移 $\mathcal{L}_{\text{vel}} = \|\Delta \mathbf{Q}^* - \Delta \mathbf{Q}^{gt}\|_1$ 。初始权重设为 $(\lambda_0, \lambda_\theta, \lambda_r, \lambda_v) = (0.5, 0.2, 0.1, 0.05)$ ，并通过验证集只调节数量级，不使用测试相机选择超参数。

4. 实验

结果填写规则。本节先固定数据、二维检测器、相机划分、指标和表格结构。所有“-”必须由同一代码版本的真实运行结果替换；在此之前不比较优劣，也不在摘要中声称超过已有方法。

4.1. 数据集与评测协议

Human3.6M (域内与合成未见相机)。Human3.6M 包含 4 个同步相机和室内动作序列 [7]。遵循

常用划分，以 S1、S5、S6、S7、S8 训练，S9、S11 测试。标准评测枚举 2、3、4 视角组合，训练时随机采样 $V \in [2, 4]$ ，不为相机槽位设置固定顺序。除标准相机外，我们从训练三维姿态重新投影构造相机环境：方位角、俯仰角、相机半径和焦距分别从预设区间采样。训练、验证、测试环境按参数区间而非随机样本划分，保证测试方位和俯仰组合从未出现。主表报告标准相机性能，泛化表报告合成域内 (ID)、插值与外推 (OOD) 性能。

TotalCapture (真实未见相机)。TotalCapture 提供 8 个同步相机、视频和惯性测量数据 [16]。本文仅使用相机观测和三维关节标注。按真实相机泛化协议，将奇数相机 {1, 3, 5, 7} 作为训练候选，偶数相机 {2, 4, 6, 8} 仅用于未见相机测试；人物划分遵循数据集公开协议。该设置检验模型是否能从合成环境学到可迁移的连续几何规律，而非记忆 Human3.6M 相机。

CMU Panoptic (可选跨数据集)。CMU Panoptic Studio 含大量同步视角和多人动作 [10]。单人阶段只选择具有稳定三维标注且主体清晰的序列。为控制下载和实验成本，训练/验证最多使用固定的 5 个分散视角；测试额外构造 2/3/4/5 视角组合，并保留未参与训练的相机。该实验是补充而非主结果：论文的核心证据应来自 Human3.6M 的可控未见环境和 TotalCapture 的真实未见相机，而不是依赖下载全部约 20 个视频视角。

跨数据集。在不使用目标数据集三维标注的情况下，分别评估 Human3.6M→TotalCapture 和 CMU→Human3.6M。必须统一关节集合、根节点定义、坐标尺度和二维检测器；若因公开方法使用不同检测器而不能严格比较，应在表中明确标注输入类型。

4.2. 统一二维输入与训练增强

二维检测器是影响多视角误差的主要混杂变量。所有自有模型和可重新运行的基线使用同一冻结检测器、同一输入分辨率及同一关节映射。训练批次中 70% 使用真实检测关键点，30% 使用真值投影加检测残差。残差库按关节类型与置信度分桶，从训练集真实检测误差估计，不访问测试三维标注。

每个训练样本先采样长度 $T = 9$ 的片段和 $V \in \{2, 3, 4\}$ 个相机，再独立应用：

- **相机环境采样：**随机方位、俯仰、半径、焦距与轻微

标定扰动；

- **相机丢弃**：以给定概率移除整路视角，模拟断流和视角数变化；
- **关节丢弃**：按置信度相关概率屏蔽单帧关节，并保留缺失掩码；
- **连续遮挡**：随机选择关节施加 3/5/9 帧连续缺失，区别于独立噪声；
- **置信度失准**：对少量样本打乱或温度缩放置信度，防止权重头照抄检测分数。

4.3. 实现细节

令特征维度 $d = 256$ 。几何-置信度视角融合和逐关节时序编码均使用 2 层、8 头 Transformer；帧内姿态融合保持与基线相同的深度和回归容量，使增益可归因于提出的设计。AdamW 初始学习率设为 2×10^{-4} ，权重衰减 10^{-2} ，余弦退火；前 5 个 epoch 对几何偏置线性暖启动。最大射线修正角为 5° ，对数方差限制在 $[-6, 4]$ 。闭式求解使用双精度累加和 ϵI 数值阻尼，网络其他部分保持单精度或自动混合精度。所有模型至少运行 3 个随机种子，表中报告均值与标准差。最终稿应补充 GPU 型号、训练时长、峰值显存、参数数量和 FLOPs。

4.4. 指标

主指标为绝对世界坐标 MPJPE (mm)，不做刚性对齐；它同时考察姿态形状和全局三维位置，更符合多视角求交任务。为与部分工作比较，可附加根对齐 MPJPE 与 PA-MPJPE，但不得用后者替代主指标。时间质量报告 MPJVE (mm/frame)、加速度误差和静态片段抖动；鲁棒性报告相对干净输入的退化量。相机泛化差距定义为

$$\Delta_{\text{gen}} = \text{MPJPE}_{\text{OOD}} - \text{MPJPE}_{\text{ID}}, \quad (15)$$

同时报告 OOD 绝对值，避免仅靠牺牲域内精度缩小差距。效率报告参数量、FLOPs、单帧延迟和序列吞吐量。

4.5. 与现有方法的比较

表 1 比较 Human3.6M 标准相机。直接三角化、可学习三角化、随机假设三角化、概率三角化、射线提升

表 1. Human3.6M 标准相机上的 MPJPE (mm，越低越好)。所有数值待实验填写；“Input” 应注明 GT、CPN、HRNet 或本研究固定检测器。

方法	Input	2 views	3 views	4 views
线性三角化	Fixed-2D	—	—	—
可学习三角化 [8]	Image	—	—	—
随机假设三角化 [1]	Fixed-2D	—	—	—
概率三角化 [9]	Fixed-2D	—	—	—
几何偏置回归 [14]	Fixed-2D	—	—	—
RUMPL [5]	Fixed-2D	—	—	—
TGR-Ray (本文)	Fixed-2D	—	—	—

表 2. 未见相机配置泛化 (MPJPE, mm)。ID 为训练分布内相机，Interp. 为未见组合的插值相机，Extra. 为方位/俯仰/焦距外推。

方法	ID ↓	Interp. ↓	Extra. ↓	$\Delta_{\text{gen}} \downarrow$
线性三角化	—	—	—	—
RUMPL	—	—	—	—
RUMPL + 环境增强	—	—	—	—
TGR-Ray (本文)	—	—	—	—

与本文方法分别代表不同的学习-几何分工。对不能在统一二维输入下重跑的方法，引用数值必须保留其原论文输入标记，不能与同检测器结果混为一列。

表 2 是本文故事线的核心表。每一行使用相同的训练姿态和二维误差库，只改变模型和环境增强；测试环境与训练参数区间严格互斥。除了平均值，还应在附录报告不同方位/俯仰网格上的误差热图。

4.6. 真实未见相机与跨数据集迁移

TotalCapture 结果见表 3。“Seen” 使用训练候选相机的未见组合，“Unseen” 只使用偶数相机。若目标数据集仅用于评测，必须关闭基于目标验证集的早停和超参数选择。跨数据集表 4 另外列出是否使用目标域二维残差标定，以区分严格零样本和无三维标注适配。

表 3. **TotalCapture 真实相机泛化**。奇数相机用于训练候选，偶数相机只用于未见相机测试。

方法	Seen	Unseen	Gap
	MPJPE	MPJPE	
线性三角化	–	–	–
RUMPL	–	–	–
TGR-Ray (本文)	–	–	–

表 4. **跨数据集零样本迁移 (MPJPE, mm)**。“2D-Cal.” 表示是否使用无三维标注的目标域二维置信度标定。

训练 → 测试	方法	2D-Cal.	MPJPE
H36M→TotalCapture	RUMPL	✗	–
H36M→TotalCapture	TGR-Ray	✗	–
H36M→TotalCapture	TGR-Ray	✓	–
CMU→H36M	RUMPL	✗	–
CMU→H36M	TGR-Ray	✗	–

4.7. 二维噪声、缺失与连续遮挡

泛化不仅是相机参数变化，还包括观测质量变化。表 5 在固定测试相机上分别添加二维高斯噪声、独立关节丢弃和连续遮挡。噪声强度按原始图像像素定义，所有方法使用完全相同的随机掩码。连续遮挡优先选择手腕、肘、踝和膝等易遮挡关节，并单独报告遮挡关节与全身误差。

4.8. 消融实验

表 6 逐步验证各设计。每个变体保持训练轮数、参数预算和增强一致。“普通视角注意力”是与 RUMPL 对齐的起点；“几何偏置”只改变式 (4)；“时序”加入式 (6)；“射线残差”加入式 (7) 但等权求交；“不确定性”加入式 (8)；“闭式求解”用式 (12) 替代自由回归出口；最后加入相机环境随机化。为证明结果不是简单增加参数造成，应增加一个参数量匹配的更深基线。

还需回答三个机制问题。第一，射线距离、三角化角和置信度是否互补，可通过逐项移除偏置验证。第二，提升来自时间上下文还是简单平滑，可与对输出应用一维滤波比较，并同时观察 MPJPE 与 MPJVE。第

三，粗姿态锚点是否只在退化几何中 useful，可按求解矩阵条件数或最小三角化角分桶绘制误差曲线。

4.9. 效率与失效分析

表 8 报告端到端推理开销。二维检测耗时和姿态提升耗时分开统计，因为前者通常占图像流水线的大部分。闭式求解针对每个关节仅求解 3×3 线性系统，其理论开销远低于增加多层全局 Transformer，但实际速度仍需在相同硬件、批量和精度模式下测量。

定性分析应选择三类代表性案例：(1) 新相机方位但二维检测清晰；(2) 单视角连续遮挡、其他视角可见；(3) 多相机近共线或同时误检。可视化原始射线、修正射线、预测权重和最终关节，验证网络是否把高权重赋给几何相容且时间稳定的观测。失败案例也必须展示，例如所有视角同一肢体被遮挡、标定严重错误或动作超出训练分布。

5. 讨论与局限性

为什么该设计可能改善泛化。TGR-Ray 的泛化并不依赖“Transformer 本身具有泛化性”这一假设，而来自结构上的约束：相机索引不进入模型；跨视角偏置由连续射线几何实时计算；射线修正被限制在局部切平面；最终三维坐标必须通过标定相机的解析方程得到。即使训练和测试相机数量或顺序不同，这些运算的含义不变。学习部分仍可利用人体和运动先验，但其主要自由度是观测质量而非场景坐标映射。

与纯三角化的边界。当二维检测非常准确且相机基线良好时，纯三角化已经接近观测上限，复杂模型不应期待大幅降低误差。本文方法更应在未见相机、少视角、近共线、置信度失准和连续遮挡下体现价值。因此论文不能只追求标准 Human3.6M 四视角上的微小数值，而应把 OOD 绝对误差、泛化差距和鲁棒性曲线作为主要证据。

局限性。本文假设相机同步且具有可用标定；严重外参漂移会使所有显式几何量同时失真。时序窗口增加了延迟，对在线系统需采用因果掩码或最新帧输出。单人骨架输入不处理跨视角多人关联；扩展到多人时，需要在射线提升前加入与相机布局无关的身份匹配或三维查询机制。合成相机环境也不能完全覆盖真实镜头畸变、滚动快门和检测器域偏移。最后，不确定性权重可能出现错误校准，因此最终稿应补充可靠性图和

表 5. 二维观测鲁棒性 (MPJPE, mm)。干净输入、像素噪声、独立关节丢弃和连续遮挡分别评测；所有结果待填写。

方法	Clean	Gaussian noise			Joint dropout			Burst occlusion		
	0	2 px	5 px	10 px	10%	20%	30%	3 f	5 f	9 f
线性三角化	—	—	—	—	—	—	—	—	—	—
RUMPL	—	—	—	—	—	—	—	—	—	—
TGR-Ray (本文)	—	—	—	—	—	—	—	—	—	—

表 6. 组件消融。ID/OOD 均在同一检测器和训练预算下评测。

变体	ID	OOD	Δ_{gen}	MPJVE
RUMPL 基线	—	—	—	—
+ 参数匹配深层基线	—	—	—	—
+ 几何-置信度偏置	—	—	—	—
+ 逐关节时序	—	—	—	—
+ 切平面射线残差	—	—	—	—
+ 异方差权重	—	—	—	—
+ 闭式射线求解	—	—	—	—
+ 相机环境随机化 (完整)	—	—	—	—

表 7. 关键设计敏感性。 θ_{max} 为最大修正角, T 为序列长度。

设置	取值	ID	OOD	MPJVE
θ_{max}	2°	—	—	—
	5°	—	—	—
	10°	—	—	—
T	1	—	—	—
	9	—	—	—
	27	—	—	—

期望校准误差, 而不只展示 MPJPE。

可证伪标准。若在统一二维检测器与相同训练预算下, 完整方法只改善域内误差、却没有降低 OOD 绝对误差或 Δ_{gen} , 则“相机泛化”故事不成立; 若简单

表 8. 模型效率。延迟在同一 GPU、 $V = 4, T = 9$ 、batch=1 下测量。

方法	Params	FLOPs	Lifter ms	FPS
RUMPL	—	—	—	—
参数匹配深层基线	—	—	—	—
TGR-Ray (本文)	—	—	—	—

时间滤波达到相同 MPJVE 且 MPJPE 更低, 则逐关节时序建模缺乏必要性; 若去除闭式求解不影响未见相机结果, 则学习-几何分工的核心论点需要重写。预先给出这些标准, 有助于避免在实验完成后选择性解释结果。

6. 结论

本文提出 TGR-Ray, 用于未见相机配置下的多视角三维人体姿态估计。方法以世界射线为基本表示, 通过几何-置信度偏置显式判断跨视角相容性, 以逐关节时序上下文识别短时噪声和连续遮挡, 并在射线切平面内联合预测受限残差与异方差。最终三维关节由不确定性加权的闭式射线求交得到, 粗姿态仅作为退化配置下的软锚点。该框架贯彻“学习噪声与运动, 解析求解相机几何”的原则, 从结构上减少对固定相机编号、数量和布局的依赖。本文已经固定域内、未见相机、跨数据集、鲁棒性、消融与效率协议; 在完成真实训练并填入表格前, 不对性能优劣作数值结论。

参考文献

- [1] Kristijan Bartol, David Bojanić, Tomislav Petković, and Tomislav Pribanić. Generalizable human pose triangulation. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*, pages 11028–11037, 2022. 1, 2, 6
- [2] Yanlu Cai, Weizhong Zhang, Yuan Wu, and Cheng Jin. PoseIRM: Enhance 3d human pose estimation on unseen camera settings via invariant risk minimization. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*, pages 2124–2133, 2024. 1, 2
- [3] Geng Chen, Pengfei Ren, Xufeng Jian, Haifeng Sun, Menghao Zhang, Qi Qi, Zirui Zhuang, Jing Wang, Jianxin Liao, and Jingyu Wang. Unified 2d-3d discrete priors for noise-robust and calibration-free multiview 3d human pose estimation. In *Advances in Neural Information Processing Systems*, 2025. 2
- [4] Seyed Abolfazl Ghasemzadeh, Alexandre Alahi, and Christophe De Vleeschouwer. MPL: Lifting 3d human pose from multi-view 2d poses. *arXiv preprint arXiv:2408.10805*, 2024. 2
- [5] Seyed Abolfazl Ghasemzadeh, Alexandre Alahi, and Christophe De Vleeschouwer. RUMPL: Ray-based transformers for universal multi-view 2d to 3d human pose lifting. *arXiv preprint arXiv:2512.15488*, 2025. 2, 6
- [6] Yihui He, Rui Yan, Katerina Fragkiadaki, and Shoou-I Yu. Epipolar transformers. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*, pages 7779–7788, 2020. 2
- [7] Catalin Ionescu, Dragos Papava, Vlad Olaru, and Cristian Sminchisescu. Human3.6M: Large scale datasets and predictive methods for 3d human sensing in natural environments. *IEEE Transactions on Pattern Analysis and Machine Intelligence*, 36(7):1325–1339, 2014. 5
- [8] Karim Iskakov, Egor Burkov, Victor Lempitsky, and Yury Malkov. Learnable triangulation of human pose. In *Proceedings of the IEEE/CVF International Conference on Computer Vision*, pages 7718–7727, 2019. 2, 6
- [9] Boyuan Jiang, Lei Hu, and Shihong Xia. Probabilistic triangulation for uncalibrated multi-view 3d human pose estimation. In *Proceedings of the IEEE/CVF International Conference on Computer Vision*, pages 14850–14860, 2023. 1, 2, 6
- [10] Hanbyul Joo, Hao Liu, Lei Tan, Lin Gui, Bart Nabbe, Iain Matthews, Takeo Kanade, Shohei Nobuhara, and Yaser Sheikh. Panoptic studio: A massively multiview system for social motion capture. In *Proceedings of the IEEE International Conference on Computer Vision*, pages 3334–3342, 2015. 5
- [11] Alex Kendall and Yarin Gal. What uncertainties do we need in bayesian deep learning for computer vision? In *Advances in Neural Information Processing Systems*, 2017. 3
- [12] Wenhao Li, Hong Liu, Hao Tang, Pichao Wang, and Luc Van Gool. MHFormer: Multi-hypothesis transformer for 3d human pose estimation. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*, pages 13147–13156, 2022. 3
- [13] Ziwei Liao, Jialiang Zhu, Chunyu Wang, Han Hu, and Steven L. Waslander. Multiple view geometry transformers for 3d human pose estimation. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*, pages 708–717, 2024. 1, 2
- [14] Olivier Moliner, Sangxia Huang, and Kalle Åström. Geometry-biased transformer for robust multi-view 3d human pose reconstruction. In *IEEE International Conference on Automatic Face and Gesture Recognition*, 2024. 1, 2, 6
- [15] Hui Shuai, Lele Wu, and Qingshan Liu. Adaptive multi-view and temporal fusing transformer for 3d human pose estimation. *arXiv preprint arXiv:2110.05092*, 2021. 2
- [16] Matthew Trumble, Andrew Gilbert, Charles Malleson, Adrian Hilton, and John Collomosse. Total capture: 3d human pose estimation fusing video and inertial sensors. In *British Machine Vision Conference*, 2017. 5
- [17] Jinlu Zhang, Zhigang Tu, Jianyu Yang, Yujin Chen, and Junsong Yuan. MixSTE: Seq2seq mixed spatio-temporal encoder for 3d human pose estimation in video. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*, pages 13232–13242, 2022. 3
- [18] Ce Zheng, Sijie Zhu, Matias Mendieta, Taojiannan Yang, Chen Chen, and Zhengming Ding. 3d human pose estimation with spatial and temporal transformers. In *Proceedings of the IEEE/CVF International Conference on Computer Vision*, pages 11656–11665, 2021. 3