

面向相机泛化的全局查询 Transformer 多视角三维人体姿态重建

陈佳尤

摘要

本文研究少视角、遮挡和未见相机配置下的多视角三维人体姿态重建。现有坐标级方法通常先在每个关节内部融合多视角观测，再利用人体结构回归三维姿态；这种先压缩视角信息、后建模全身关系的处理顺序，会使困难关节在少视角条件下过早丢失其他关节和完整相机集合提供的判别证据。为此，本文将多视角二维姿态序列到绝对三维姿态的映射建模为全局查询回归问题，提出一种面向相机泛化的编码器-解码器 *Transformer*。编码端将二维关键点转换为世界坐标射线，并行构造逐关节视角集合表征与完整关节-视角记忆；解码端采用由三角化锚点条件化的关节查询，从全局记忆中恢复三维残差，使每个关节在视角压缩之前即可利用全身和多相机证据。模型进一步联合评价不同相机子集和稳健几何求解器产生的三维假设，并利用轻量级时序残差建模帧内骨架关系与逐关节运动轨迹。整个三维网络仅接收二维坐标、检测置信度和标定相机射线，不使用相机编号或固定视角槽位，因而能够处理数量和排列可变的输入相机。在 *Human3.6M* 清洁测试集上，九帧最终模型以 *ResNet-152* 二维输入取得 31.215/22.008/19.971 mm 的两、三、四视角绝对 *MPJPE*，并以通用 *HRNet* 二维输入取得 37.704/29.231/27.219 mm。消融实验表明，全局关节查询主要缓解两视角深度歧义，多假设效用融合主要改善三、四视角结果，而时序残差在三种视角数下均带来一致收益。

1. 引言

三维人体姿态估计是计算机视觉中的基础问题，广泛应用于体育分析、机器人、虚拟现实和角色动画等领域。准确恢复人体在世界坐标系中的三维关节位置，是理解人体运动、行为及其与环境交互的重要前提。

尽管单目图像和视频中的三维人体姿态估计已取得显著进展，但从单一视角恢复三维结构仍存在固有困难。一方面，二维投影会丢失深度信息，同一二维姿态可能对应多个三维解释；另一方面，肢体自遮挡和场景遮挡会造成关键点缺失或定位偏差，使单目方法难以稳定恢复绝对三维位置。

利用多个相机观察同一人体，是缓解深度歧义和遮挡问题的自然途径。典型多视角系统首先在各相机中独立检测二维关键点，再通过三角化或学习式融合恢复三维姿态 [1, 7, 10, 11]。不同视角之间的视差提供了绝对深度约束，而一个视角中被遮挡的关节也可能在其他视角中可见。因此，在相机标定可靠且观测充分时，多视角方法通常能够获得比单目方法更稳定的三维重建。

然而，公开多视角数据集通常在中心化捕获区域内布置固定相机，并具有较强的视域重叠和相对有限的遮挡。实际部署则受到场地大小、设备成本、安装位置和供电条件的约束，往往只能使用少量宽基线相机；被测人员还可能进入仅由部分相机覆盖的区域，或受到家具和其他人员的持续遮挡。在分布式实时系统中，传输原始图像或中间特征也可能带来较高通信开销，而二维骨架是一种更紧凑的输入形式。由此，实际系统需要在仅提供多视角二维关键点的条件下，同时适应较少的有效视角、变化的相机数量和训练阶段未出现的空间布局。

面向上述条件，解析几何与学习式回归各有局限。加权可微三角化能够直接利用相机投影关系 [7]，随机假设评分则通过评价不同视角子集生成的三维候选减弱对固定布局的依赖 [1]；但这类方法仍会受到二维误检、退化基线和连续遮挡的显著影响。另一类方法利用 *Transformer* 融合多视角二维骨架或图像特征。Moliner 等人将不同视角、时间和关节的观测表示为统一令牌，并以射线距离和检测置信度引导全局注意力 [11]；Liao

等人将视角相关的三维推理交由无学习几何模块处理,使可学习部分集中于图像证据和二维姿态修正 [10]; Ghasemzadeh 等人采用世界坐标射线和视角共享权重,使模型能够接收数量可变的二维姿态 [4]。这些研究表明,显式几何表示和全局信息交互是提高相机泛化能力的关键。

尽管如此,现有坐标级射线提升方法仍存在一个容易被忽略的信息瓶颈:多视角观测通常先在每个关节内部完成压缩,随后才在关节维度建模人体结构。对于可见性良好且射线条件稳定的关节,这种分层处理能够有效降低计算量;但在仅有两个有效视角、相机基线退化或局部关节误检时,单个关节的射线证据往往不足以确定可靠深度。如果腕部或踝部的全部视角令牌已被压缩为单一表示,后续人体结构模块只能处理压缩结果,无法再根据躯干、对侧肢体和其他相机中的原始观测判断哪些证据可信。相机数量增加也不必然消除该问题,因为新增视角可能同时引入新的遮挡和误检。因而,少视角条件下的关键并非单纯增加网络容量,而是推迟不可逆的视角压缩,使每个关节在形成三维估计之前能够访问完整的全身多视角证据。

基于这一认识,本文将多视角二维姿态序列到绝对三维姿态的映射建模为全局查询回归问题,并提出一种面向相机泛化的编码器-解码器 Transformer。模型首先根据二维关键点和相机标定构造世界坐标射线,并以置信度加权的射线交点提供绝对位置锚点。编码端并行形成逐关节视角集合表征与完整的“关节 $\times$ 视角”记忆:前者以共享参数适应可变视角数量和排列,后者在压缩之前保存全部观测。解码端为每个人体关节设置一个由三角化锚点条件化的查询,使其能够同时检索所有关节和所有可用相机中的证据。查询分支仅预测有界三维残差,且输出层采用零初始化,从而在训练初始阶段保持基础空间估计,并在联合训练中逐步学习全局修正。

仅依赖单个全局预测仍可能受到局部异常观测影响。为此,本文从当前可用相机的合法子集以及稳健几何求解器中生成互补三维假设,并由置换等变的集合评分器建模候选之间的相对关系 [9]。评分过程综合候选共识、点到射线距离、重投影统计、检测置信度和射线条件,不使用相机编号;模型随后预测逐关节相对风险并执行软融合。该设计使不同视角数量共享同一候选评价规则,并通过恒等保持约束避免在基础估计已

经可靠时引入明显退化。

时间信息为判断二维检测误差提供了另一种互补证据。不同于仅对最终姿态进行平滑,本文在空间融合结果之后编码根相对姿态、绝对根位置、速度和加速度近似,先建模每一帧内的骨架关系,再沿时间维分别建模各关节轨迹。逐关节时序建模能够保留不同身体部位的运动差异 [14],并有助于区分瞬时检测抖动、连续遮挡和真实运动。时序分支同样采用零初始化的有界残差,且不修改绝对根位置,使其作为空间重建的受限补充,而不改变相机几何主线。

本文首先在 Human3.6M 清洁协议下评估少视角精度,并对两种冻结二维前端采用一致的数据划分、相机组合与绝对误差度量。使用 ResNet-152 坐标输入时,九帧最终模型在两、三、四视角下分别取得 31.215/22.008/19.971 mm;使用通用 HRNet 坐标输入时,对应结果为 37.704/29.231/27.219 mm。分阶段消融进一步表明,全局关节查询的主要收益集中在两视角设置,多假设效用融合主要改善三、四视角精度,而九帧时序残差在全部视角数下均产生一致增益。实验章节同时按照统一协议预留遮挡、跨数据集和不同时间长度的后续比较表,以避免在评价设置变化时混用结果。

本文的主要贡献概括如下:

- 提出一种面向相机泛化的全局查询 Transformer,将世界射线几何、可变视角集合聚合与完整关节-视角记忆统一建模,使每个关节在视角压缩之前访问全身多视角证据。
- 提出由三角化锚点条件化的关节查询和零初始化残差学习机制,在不重新学习相机投影关系的条件下修正少视角和退化相机对中的深度歧义。
- 构建统一的多假设与时序鲁棒推理策略,分别利用相机子集之间的互补性和逐关节运动轨迹,提高模型对局部异常观测与连续遮挡的适应能力。
- 建立覆盖不同二维前端、全部相机组合、遮挡场景和跨数据集迁移的匹配评测协议,以分别度量少视角精度和相机配置泛化能力。

本文其余部分组织如下:第 2 节回顾多视角三维人体姿态重建、相机配置泛化及姿态序列建模的相关研究;第 3 节详细介绍所提方法,包括几何射线表征、全局关节查询、多假设效用融合和时序残差精化;第 4 节

给出实验设置、与现有方法的定量比较及消融分析；第 5 节总结全文，并讨论方法局限与未来研究方向。

2. 相关工作

2.1. 几何约束的多视角三维姿态重建

多视角三维人体姿态估计通常遵循“二维检测-跨视角融合-三维恢复”的处理范式。Iskakov 等人将相机投影关系写入可微代数三角化，并进一步在统一三维体素空间中融合多视角图像特征 [7]。Qiu 等人利用跨视角特征融合改善二维关键点，再通过递归图模型逐级缩小三维搜索空间 [12]。He 等人沿极线检索相邻视角的对应特征，使二维检测阶段能够利用多视角几何信息 [5]。这些方法能够在固定捕获系统中取得较高精度，但图像特征传输、三维体素构造或与相机布局相关的融合参数，会增加计算与通信开销，并限制其直接迁移到相机数量和位置变化的场景。

近期研究尝试在可学习表征与解析几何之间建立更明确的分工。Liao 等人使用无学习的几何模块完成视角相关的三维推理，并用外观模块迭代修正遮挡条件下的二维观测 [10]。这种混合设计说明，将已知投影规律交由几何运算处理，有助于减弱神经网络对训练相机布局的记忆。与上述图像级方法不同，本文关注坐标级输入：冻结的二维前端在各视角独立运行，三维网络仅传输关键点坐标、置信度和标定射线。该设定牺牲了外观纹理线索，但更适合带宽受限、二维前端异构或相机端独立部署的系统。

2.2. 相机配置泛化的坐标级建模

相机泛化要求模型在测试时适应训练阶段未出现的相机位置、排列和有效视角数量。Bartol 等人从随机视角子集构造三维假设，并学习与具体空间布局解耦的假设评价函数 [1]。Cai 等人通过合成多种相机设置并约束不同环境下的风险一致性，降低坐标提升网络对有限训练视角的过拟合 [2]。上述方法分别从随机假设和优化目标出发改善泛化，但当二维检测包含离群点或仅有两个有效视角时，解析三角化仍可能产生不稳定深度。

另一条技术路线将二维关键点转化为世界坐标中的相机射线。Moliner 等人把跨时间、视角和关节的射线观测组织为统一令牌，并利用检测置信度及射线间距离调制注意力 [11]。Ghasemzadeh 等人采用共享的

射线编码与分层 Transformer，先在每个关节内聚合可变量数量的视角，再建模全身关节关系 [4]。世界射线避免网络隐式学习投影关系，共享权重也天然兼容视角置换；然而，逐关节视角融合会在全身关系建模之前将多个观测压缩为单个表示。针对这一处理顺序，本文并行构造逐关节视角集合表征与完整的“关节 $\times$ 视角”记忆，使各关节查询能够在压缩前检索全身多视角证据。

2.3. 姿态假设评价与时序建模

不完整观测下的三维重建还可借助候选共识与运动连续性。Lee 等人通过基于注意力的集合编码器建模元素间高阶关系，并保持输入置换不变性 [9]；Bartol 等人的研究进一步表明，相机子集产生的三维假设可通过学习式评分实现稳健组合 [1]。本文将学习式回归和稳健几何产生的候选统一视为无序集合，以逐关节相对风险代替单一姿态分数，从而允许不同身体部位选择不同的可靠证据。

对于视频输入，Zheng 等人先编码单帧关节间的空间关系，再聚合跨帧信息以预测中心帧姿态 [16]。Zhang 等人进一步交替建模关节和时间维度，使不同关节的局部运动模式得到保留 [14]。这些工作主要研究单目根相对姿态提升，而本文的时序模块作用于多视角空间融合之后：它同时编码根相对姿态、绝对根位置及运动差分，并仅预测有界的中心帧残差。因此，时间信息用于修正短时检测异常，而绝对位置仍由标定相机几何和空间重建分支决定。

3. 方法

3.1. 问题定义与总体框架

给定时刻 t 的同步相机集合 $\mathcal{V}_t$ ，冻结的二维姿态估计器为视角 v 和关节 j 输出齐次像素坐标 $\mathbf{x}_{tvj}^0 = (u_{tvj}^0, v_{tvj}^0, 1)^\top$ 及检测置信度 c_{tvj} 。多视角观测修正模块将其转换为一致性更强的二维观测 $\mathbf{x}_{tvj}$ 。相机内参与世界到相机的外参分别记为 $\mathbf{K}_v$ 和 $(\mathbf{R}_v, \mathbf{t}_v)$ 。本文目标是在世界坐标系中估计 J 个关节的绝对三维位置 $\hat{\mathbf{P}}_t = \{\hat{\mathbf{p}}_{tj}\}_{j=1}^J$ 。整个重建网络仅接收二维坐标、置信度与相机标定，不接收 RGB、热图、检测框、二维主干特征或相机身份编码；输入相机的数量与排列均可变化。

常见的层次式多视角建模先将同一关节的跨视角

证据压缩为单个向量，再建模人体关节关系。该策略结构清晰，但压缩后的人体编码器无法重新访问某一视角中的原始射线，也难以借助其他关节判断局部观测是否可靠。本文由此将延迟视角压缩作为核心设计：在保留稳定层次路径的同时，额外维护完整关节-视角记忆，使每个关节查询在输出三维坐标之前直接检索全部有效观测。

图 1 给出总体框架。首先，多视角观测修正 (Multi-view Observation Refinement, MOR) 在不引入 RGB 特征的前提下，利用同步视角间的一致性修正噪声二维关节。随后，几何-可靠性融合 (Geometry-Reliability Fusion, GRF) 将修正后的观测转换为世界射线与锚点中心化令牌，由层次基础路径和全局关节查询路径生成学习式姿态假设，并联合稳健三角求解产生的几何假设进行可靠性评估与逐关节软融合。最后，空间-时间精化 (Spatial-Temporal Refinement, STR) 在九帧中心窗口内建模帧内骨架关系与逐关节轨迹，仅对中心帧输出残差修正。

3.2. 几何条件化的射线表征

世界射线。 像素坐标随相机内参和相机姿态改变。由标定参数计算相机中心及关节观测对应的单位世界方向：

$$\mathbf{o}_v = -\mathbf{R}_v^\top \mathbf{t}_v, \quad \mathbf{d}_{tvj} = \text{norm}(\mathbf{R}_v^\top \mathbf{K}_v^{-1} \mathbf{x}_{tvj}), \quad (1)$$

其中 $\text{norm}(\mathbf{a}) = \mathbf{a} / \|\mathbf{a}\|_2$ 。式 (1) 将数据集相关的像素位置转换为物理含义一致的三维射线，使相机布局变化显式体现为射线起点与方向的变化。

置信度加权锚点。 单条射线无法确定深度，近平行射线也会导致三角求解不稳定。令

$$\mathbf{Q}_{tvj} = \mathbf{I} - \mathbf{d}_{tvj} \mathbf{d}_{tvj}^\top, \quad w_{tvj} = c_{tvj} + \epsilon, \quad (2)$$

则最小化候选点到所有有效射线正交距离的正则化法方程为

$$\mathbf{A}_{tj} = \sum_{v \in \mathcal{V}_{tj}} w_{tvj} \mathbf{Q}_{tvj} + \lambda \mathbf{I}, \quad (3)$$

$$\mathbf{b}_{tj} = \sum_{v \in \mathcal{V}_{tj}} w_{tvj} \mathbf{Q}_{tvj} \mathbf{o}_v, \quad \mathbf{a}_{tj} = \text{solve}(\mathbf{A}_{tj}, \mathbf{b}_{tj}), \quad (4)$$

其中 $\mathcal{V}_{tj}$ 为关节 j 的有效观测集合，本文取 $\epsilon = 0.05$ 、 $\lambda = 10^{-4}$ 。锚点 $\mathbf{a}_{tj}$ 仅提供绝对几何条件和稳定初值，并不直接作为最终预测。

锚点中心化令牌。 为减弱不同捕获空间整体平移造成的分布偏移，以根关节锚点 $\mathbf{a}_{tr}$ 为局部原点，构造 Plücker 方向与矩：

$$\mathbf{o}'_{tv} = \mathbf{o}_v - \mathbf{a}_{tr}, \quad \mathbf{m}_{tvj} = \mathbf{o}'_{tv} \times \mathbf{d}_{tvj}. \quad (5)$$

共享射线编码器将几何量与置信度映射为令牌

$$\mathbf{z}_{tvj} = f_{\text{ray}}([\mathbf{d}_{tvj}; \mathbf{m}_{tvj}; c_{tvj}]) \in \mathbb{R}^D. \quad (6)$$

编码器在全部相机间共享参数，缺失观测通过掩码处理，令牌中不加入相机身份嵌入。

3.3. 全局关节查询空间生成器

层次基础路径。 设 $\mathcal{F}_{\text{view}}$ 表示同一关节的可变视角集合编码器， $\mathcal{F}_{\text{body}}$ 表示关节维度的人体结构编码器。基础预测写为

$$\mathbf{h}_{tj} = \mathcal{F}_{\text{view}}(\{\mathbf{z}_{tvj} \mid v \in \mathcal{V}_{tj}\}), \quad (7)$$

$$[\mathbf{g}_{t1}, \dots, \mathbf{g}_{tJ}] = \mathcal{F}_{\text{body}}([\mathbf{h}_{t1}, \dots, \mathbf{h}_{tJ}]), \quad (8)$$

$$\hat{\mathbf{p}}_{tj}^{\text{base}} = \mathbf{a}_{tj} + f_{3D}(\mathbf{g}_{tj}). \quad (9)$$

该路径先比较同一语义关节的跨视角证据，再传播全身结构信息，因而提供稳定的基础姿态。然而， $\mathbf{h}_{tj}$ 已将多个视角压缩为一个向量，后续人体编码器不能重新检索压缩前的细粒度观测。

完整关节-视角记忆。 为保留全局决策所需的原始证据，在执行逐关节视角压缩之前构造


$$\mathcal{M}_t = \{\mathbf{z}_{tvk} + \mathbf{e}_k^{\text{mem}} \mid k = 1, \dots, J; v \in \mathcal{V}_{tk}\}, \quad (10)$$

其中 $\mathbf{e}_k^{\text{mem}}$ 只编码关节语义，不编码相机身份。所有关节均可见时，记忆长度为 KJ ，其中 $K = |\mathcal{V}_t|$ ；相机数量变化只改变记忆长度，不改变模型参数。

锚点条件化查询。 每个关节对应一个可学习语义查询。为使其同时具有当前样本的绝对几何条件，定义

$$\mathbf{q}_{tj}^0 = \mathbf{q}_j^{\text{learn}} + \mathbf{W}_a \mathbf{a}_{tj}. \quad (11)$$

(a) Camera-generalizable reconstruction pipeline



(b) Geometry-reliability fusion (GRF)




图 1. 所提方法总体框架。(a) 多视角二维姿态序列在 $t-4:t+4$ 窗口内输入；MOR 先修正噪声二维观测，GRF 再综合学习式与几何姿态假设，STR 通过两层空间注意力 (SA) 和两层时间注意力 (TA) 估计中心帧残差，得到绝对三维姿态。(b) GRF 细节。修正后的二维观测分别经由全局关节查询回归器和稳健三角求解器产生多个相机子集假设；可靠性评分器根据二维置信度、重投影误差和跨视角一致性估计逐关节权重，并通过自适应软融合输出空间姿态。所有视角相关运算均共享参数，不依赖相机编号或固定视角槽位。

两层 Transformer 解码器以 J 个关节查询作为 Query，以 $\mathcal{M}_t$ 作为 Key 和 Value。为简明起见，单头跨注意力可写为

$$\mathbf{C}_t^\ell = \text{softmax} \left(\frac{(\mathbf{Q}_t^{\ell-1} \mathbf{W}_q^\ell)(\mathbf{M}_t \mathbf{W}_k^\ell)^\top}{\sqrt{d}} \right) (\mathbf{M}_t \mathbf{W}_v^\ell), \quad (12)$$

其中， $\mathbf{M}_t$ 为记忆令牌矩阵，缺失观测在 softmax 前被屏蔽。查询经多头跨注意力、残差连接和前馈网络更新。由此，困难关节不仅能比较自身在不同相机中的射线，还可直接检索躯干、相邻骨骼和对侧肢体的原始多视角证据。

有界残差输出。 全局分支不直接替代基础预测，而仅学习三维修正：

$$\Delta \mathbf{p}_{tj}^{\text{GQ}} = s_g \tanh(\mathbf{W}_o \text{LN}(\mathbf{q}_{tj}^2)), \quad (13)$$

$$\hat{\mathbf{p}}_{tj}^{\text{GQ}} = \hat{\mathbf{p}}_{tj}^{\text{base}} + \Delta \mathbf{p}_{tj}^{\text{GQ}}, \quad (14)$$

其中 $s_g = 0.5$ ，输出投影 $\mathbf{W}_o$ 采用零初始化，使新增分支在训练起点严格退化为恒等映射。由于记忆注意力仅包含共享射线令牌和关节语义，输入相机的任意排列只改变求和顺序；softmax 的归一化范围又可随记忆长度变化，故同一组参数可兼容不同的视角排列与数量。

3.4. 多假设逐关节效用融合

单次全视角回归可能受某个异常二维检测影响，而“增加相机”也不保证每个关节均得到改善。为此，对当前有效相机的合法子集 $s \in \mathcal{S}_t$ ，分别生成学习式候选 $\hat{\mathbf{P}}_s^{\text{GQ}}$ 与置信度加权的稳健几何候选 $\hat{\mathbf{P}}_s^{\text{geo}}$ ：

$$\mathcal{C}_t = \left\{ \hat{\mathbf{P}}_s^{\text{GQ}}, \hat{\mathbf{P}}_s^{\text{geo}} \mid s \in \mathcal{S}_t \right\}. \quad (15)$$

在四相机设置中，二、三、四视角组合共形成 $6+4+1=11$ 个子集，两类估计器合计产生 22 个候选。若候选使用了当前不可用相机，则在集合注意力和权重归一化

中予以屏蔽。

稳健几何候选通过迭代重加权最小二乘降低异常射线的影响，其目标为

$$\hat{\mathbf{p}}_{sj}^{\text{geo}} = \arg \min_{\mathbf{p}} \sum_{v \in s} c_{vj} \rho(\|\mathbf{Q}_{vj}(\mathbf{p} - \mathbf{o}_v)\|_2), \quad (16)$$

其中 $\rho(\cdot)$ 为稳健代价。该分支提供可解释的多射线一致性，学习式候选则能够利用全身结构处理近平行射线与局部缺失，二者具有互补的误差模式。

候选特征与集合评分。 评分器根据候选能否解释当前观测推断逐关节相对风险，而不使用相机身份。对候选 c 的关节 j ，特征包含：(1) 绝对与根相对姿态；(2) 候选相对集合共识的偏差；(3) 子集内外的点到射线距离、重投影残差和置信度统计；(4) 加权射线法矩阵

$$\mathbf{G}_{sj} = \sum_{v \in s} c_{vj} \mathbf{Q}_{vj} \quad (17)$$

的特征值、子集视角比例与全局姿态上下文；(5) 关节语义。两层置换等变集合编码器在候选维度交换信息并输出风险 r_{cj} 。

给定视角数量相关的温度 τ_K ，融合权重与输出为

$$\alpha_{cj} = \frac{\exp(-r_{cj}/\tau_K)}{\sum_{c' \in \mathcal{C}_t} \exp(-r_{c'j}/\tau_K)}, \quad (18)$$

$$\hat{\mathbf{p}}_{tj}^{\text{E2}} = \sum_{c \in \mathcal{C}_t} \alpha_{cj} \hat{\mathbf{p}}_{cj}. \quad (19)$$

逐关节权重允许同一帧的躯干、手腕与脚踝采用不同候选。本文取 $\tau_2 = 0.4$ 、 $\tau_3 = \tau_4 = 1.8$ 。评分器先以候选真实逐关节误差进行直接风险监督，再以融合误差进行微调。为避免基础估计已可靠时发生退化，引入

$$\mathcal{L}_{\text{id}} = \lambda_{\text{id}} \sum_K \gamma_K [E_{\text{soft}}^K - E_{\text{base}}^K]_+, \quad (20)$$

其中 $[x]_+ = \max(0, x)$ ， $\lambda_{\text{id}} = 0.25$ ， $\gamma_2 = 4$ ， $\gamma_3 = \gamma_4 = 1$ 。双视角条件信息最少，因此采用更强的恒等保持约束。

3.5. 空间--时间残差精化

逐帧空间估计难以区分二维关键点的瞬时抖动与真实快速运动。本文冻结空间融合器，并在其输出上学习中心帧的局部时序残差。令 $\mathbf{p}_{tj} = \hat{\mathbf{p}}_{tj}^{\text{E2}}$ 、 $\mathbf{v}_{tj} = \mathbf{p}_{tj} - \mathbf{p}_{t-1,j}$ ，每个关节的十二维输入为

$$\mathbf{u}_{tj} = [\mathbf{p}_{tj} - \mathbf{p}_{tr}; \mathbf{p}_{tr}; \mathbf{v}_{tj}; \mathbf{v}_{tj} - \mathbf{v}_{t-1,j}]. \quad (21)$$

四项分别描述局部骨架、绝对根位置、速度与离散加速度。对长度 T 的窗口，网络先在每帧内沿关节维执行两层空间 Transformer，再对每个关节沿时间维执行两层时间 Transformer：

$$\mathbf{S}_{\tau, :, :} = \mathcal{F}_{\text{spa}}(\mathbf{U}_{\tau, :, :}), \quad \mathbf{H}_{:, j, :} = \mathcal{F}_{\text{tmp}}(\mathbf{S}_{:, j, :}). \quad (22)$$

当前实现使用九帧非因果中心窗口，即利用前后各四帧预测中心帧。最终输出为

$$\Delta \mathbf{p}_{tj}^{\text{temp}} = s_t \tanh(f_{\text{ST}}(\mathbf{H}_{t, j, :})), \quad (23)$$

$$\hat{\mathbf{p}}_{tj}^{\text{T}} = \hat{\mathbf{p}}_{tj}^{\text{E2}} + \Delta \mathbf{p}_{tj}^{\text{temp}}, \quad (24)$$

其中 $s_t = 0.1$ ，输出层采用零初始化，并固定根关节修正为零。时序分支因此只校正相对关节轨迹，不改变由多视角几何确定的绝对根位置。

3.6. 训练与推理

空间生成器首先以绝对三维关节误差联合训练：

$$\mathcal{L}_{\text{GQ}} = \frac{1}{TJ} \sum_{t,j} \|\hat{\mathbf{p}}_{tj}^{\text{GQ}} - \mathbf{p}_{tj}^*\|_2. \quad (25)$$

训练前 8 个 epoch 均匀采样双视角组合，随后按 3:1:1 采样双、三、四视角组合，总计训练 20 个 epoch，学习率为 10^{-4} 。之后冻结空间生成器，候选评分器依次进行 10 个 epoch 的直接风险学习和 5 个 epoch 的融合误差微调。最后冻结上述模块，训练九帧时序残差网络 12 个 epoch。各阶段共享同一空间生成器权重，不针对不同相机组合训练独立模型。

推理时，几何前端和空间生成器首先对当前合法相机子集产生学习式与稳健几何候选；集合评分器屏蔽依赖缺失相机的候选并完成逐关节融合；视频模式进一步缓存相邻帧姿态并输出中心帧时序修正。射线编码、全局记忆和候选评分均不依赖相机编号，因此无需为新的相机顺序改变网络结构。

4. 实验

4.1. 实验设置

数据集与划分。 本文首先在 Human3.6M (H36M) 数据集 [6] 上验证少视角三维姿态重建性能。训练集合并 S1、S5、S6、S7 和 S8，测试集采用 S9 与 S11，并按照既有多视角评测协议 [7, 11] 排除 S9 中已知的错误

片段。遮挡鲁棒性实验沿用 H36M-Occl 和 Occlusion-Person [11, 15] 设置；跨数据集实验采用 CMU Panoptic [8] 训练、H36M 测试的零样本迁移协议。尚未完成的实验在表中保留空白单元格，不参与正文结论。

二维输入。 为区分三维重建器与二维检测器的影响，本文采用两种冻结的坐标级前端。ResNet-152[†] 表示由可学习三角化工作 [7] 发布并在 H36M 上微调的二维检测器；HRNet 表示由 YOLOX-X 人体框和 COCO 预训练 HRNet-W32 [3, 13] 构成的通用前端。三维网络仅接收各关节的 $(x, y, \text{confidence})$ 、相机参数和对应世界射线，不读取 RGB、热图、人体框或二维网络中间特征。

评价指标。 本文报告全部 17 个关节的绝对平均关节位置误差 (MPJPE)，单位为毫米。预测与真值之间不进行根关节对齐、尺度校正或 Procrustes 对齐。主结果采用动作等权平均：V2 汇总全部 6 个双相机组合，V3 汇总全部 4 个三相机组合，V4 使用全部四个相机。单帧模型记为 $T=1$ ，九帧中心窗口模型记为 $T=9$ ；后者利用中心帧前后各四帧，因此不作为因果在线结果。模型选择仅依据训练主体留出的验证数据，S9/S11 只用于最终测试。

实现细节。 空间生成器、候选评分器与时序精化器采用第 3 节所述分阶段训练策略。空间阶段在训练过程中采样不同相机子集，但不同视角数共享同一组模型权重；候选效用融合在冻结空间生成器后训练，随后冻结空间分支并训练九帧时序残差网络。除特别说明外，表中本文结果均为九帧最终模型。

4.2. 不同视角数下的重建精度

表 1 比较两种二维前端下的少视角重建误差。为保证可追溯性，代数三角化与几何偏置 Transformer 的数值均按其公开论文 [11] 所报告的精度列出；本文结果由相同 H36M 测试划分上的全部相机组合汇总得到。

ResNet-152[†] 输入下，本文方法在三、四视角分别达到 22.008 和 19.971 mm，相比九帧参考方法降低 2.392 和 2.729 mm；两视角误差为 31.215 mm，与其报告值相差 1.315 mm。使用不经 H36M 微调的 HRNet 输入时，本文方法在三视角下取得 29.231 mm，较参考结果降低 1.169 mm，同时将代数三角化的三视角误差

表 1. H36M 不同输入视角数下的绝对 MPJPE (mm，越低越好)。† 表示二维检测器在 H36M 上微调；外部方法保留其论文中的报告精度。

方法	二维输入	T	V2	V3	V4
代数三角化 [7]	ResNet-152 [†]	1	51.1	23.4	19.1
Moliner 等 [11]	ResNet-152 [†]	9	29.9	24.4	22.7
本文方法	ResNet-152 [†]	9	31.215	22.008	19.971
代数三角化 [7]	HRNet	1	120.7	50.9	44.2
Moliner 等 [11]	HRNet	9	36.8	30.4	26.0
本文方法	HRNet	9	37.704	29.231	27.219

表 2. H36M-Occl 上的绝对 MPJPE (mm，越低越好)。公开比较值引自 [11]。

方法	二维输入	T	V2	V3	V4
代数三角化 [7]	ResNet-152 [†]	1	163.3	39.5	27.9
Moliner 等 [11]	ResNet-152 [†]	9	39.1	33.4	31.3
本文方法	ResNet-152 [†]	9			
代数三角化 [7]	HRNet	1	217.3	72.4	54.1
Moliner 等 [11]	HRNet	9	42.3	34.5	31.6
本文方法	HRNet	9			

由 50.9 mm 降至 29.231 mm。结果表明，所提重建器能够适配不同来源的二维坐标，但收益随二维前端和视角数而变化，因此本文不将单一列优势扩展为全部设置下的统一领先结论。

4.3. 遮挡场景评估

遮挡实验遵循“仅在清洁训练集训练、直接在遮挡测试集评估”的设置，以检验模型是否依赖遮挡测试数据调参。表 2 与表 3 列出公开比较值并预留本文结果行；空白项不参与当前阶段的定量分析。

4.4. 跨数据集相机泛化

表 4 采用 CMU Panoptic 训练、H36M 测试的零样本迁移设置，并仅在两个数据集语义一致的肩、肘、腕、膝和踝关节上计算绝对 MPJPE。该实验将人体动作分布变化与未见相机布局同时纳入评价，因此单独报告各动作结果，而不与 H36M 全 17 关节主表混合。

表 3. Occlusion-Person 上的绝对 MPJPE (mm, 越低越好)。† 表示二维检测器在目标数据集上微调；公开比较值引自 [11, 15]。

方法	二维输入	2	3	4	8
RANSAC [15]	HRNet [†]	33.7	87.5	35.0	15.5
ScoreFuse [15]	HRNet [†]	32.7	25.7	21.4	15.0
AdaFuse [15]	HRNet [†]	—	26.2	19.7	12.6
Moliner 等 [11]	HRNet	30.8	22.9	19.6	14.2
本文方法	HRNet				

表 4. 从 CMU Panoptic 训练集到 H36M 测试集的跨数据集泛化。数值为绝对 MPJPE (mm, 越低越好)，公开比较值引自 [11]。

方法	输入	Dir	Disc	Eat	Greet	Phone	Pose	Purch	Sit
代数三角化 [7]	HRNet	44.6	43.5	42.2	42.5	43.7	41.6	48.5	46.8
Moliner 等 [11]	HRNet	33.9	32.5	32.6	33.7	38.3	30.8	35.1	56.9
本文方法	HRNet								

方法	输入	SitD	Smoke	Photo	Wait	Walk	WalkD	WalkT	Avg
代数三角化 [7]	HRNet	51.7	45.4	45.7	42.3	40.3	45.6	39.8	44.3
Moliner 等 [11]	HRNet	85.9	36.0	37.9	33.3	29.1	38.7	28.7	38.9
本文方法	HRNet								

表 5. H36M 上的核心组件消融。数值为全部相机组合的绝对 MPJPE (mm, 越低越好)。

模型配置	T	$V2$	$V3$	$V4$
逐关节视角压缩生成器	1	41.470	26.081	24.157
+ 全局关节查询	1	32.312	25.101	23.536
+ 多假设效用融合	1	32.331	22.646	20.361
+ 恒等保持校准	1	32.319	22.558	20.272
+ 九帧时序精化	9	31.215	22.008	19.971

4.5. 消融实验

核心组件。 表 5 按照实际推理链逐步加入全局关节查询、多假设效用融合、恒等保持校准和九帧时序精化。所有行采用相同 ResNet-152[†] 坐标输入；候选融合的单帧结果为两个随机种子的均值。

全局关节查询将两视角误差降低 9.158 mm，并在三、四视角分别降低 0.980 和 0.621 mm，说明在观测

表 6. 时间窗口长度对四视角绝对 MPJPE (mm) 的影响。本文 $T=1$ 与 $T=9$ 使用相同的稠密中心样本。

数据集与方法	二维输入	1	2	3	6	9
H36M, Moliner 等 [11]	HRNet	29.4	27.9	27.7	27.3	26.0
H36M, 本文方法	ResNet-152 [†]	20.306				19.971
H36M, 本文方法	HRNet	27.371				27.219
H36M-Occl, Moliner 等 [11]	HRNet	41.5	34.9	34.0	32.5	31.6
H36M-Occl, 本文方法	ResNet-152 [†]					
H36M-Occl, 本文方法	HRNet					

最少时，允许困难关节访问完整关节-视角记忆尤为重要。多假设效用融合进一步将三、四视角误差降低至 22.646 和 20.361 mm，而两视角基本保持不变，表明相机子集增多后，候选之间的互补性更易被利用。恒等保持校准仅产生 0.012/0.088/0.089 mm 的稳定修正，因此其作用被界定为抑制融合负增益，而非主要精度来源。

时间窗口长度。 表 6 采用四视角和匹配的时序中心样本比较时间窗口长度。本文当前完成 $T=1$ 与 $T=9$ 两个端点；中间长度与遮挡测试单元格保持空白。参考方法使用历史帧预测最新帧，而本文使用前后对称的中心窗口，故两者用于观察时间信息趋势，不视为严格一致的因果对照。

在匹配的稠密中心样本上，九帧时序精化使 ResNet-152[†] 输入的两、三、四视角误差分别降低 1.222/0.572/0.335 mm，并使 HRNet 输入分别降低 1.123/0.407/0.153 mm。收益随视角数增加而减小，说明时间证据主要补偿少视角条件下更强的瞬时深度歧义；同时，全部六个设置均未发生精度退化，支持将时序分支保留在最终模型中。

参考文献

- [1] Kristijan Bartol, David Bojanić, Tomislav Petković, and Tomislav Pribanić. Generalizable human pose triangulation. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*, pages 11028–11037, 2022. 1, 3
- [2] Yanlu Cai, Weizhong Zhang, Yuan Wu, and Cheng Jin. PoseIRM: Enhance 3d human pose estimation on unseen camera settings via invariant risk minimization. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*, pages 2124–2133, 2024. 3
- [3] Zheng Ge, Songtao Liu, Feng Wang, Zeming Li, and

- Jian Sun. YOLOX: Exceeding YOLO series in 2021. *arXiv preprint arXiv:2107.08430*, 2021. 7
- [4] Seyed Abolfazl Ghasemzadeh, Alexandre Alahi, and Christophe De Vleeschouwer. RUMPL: Ray-based transformers for universal multi-view 2d to 3d human pose lifting. *IEEE Transactions on Image Processing*, 35:5509–5522, 2026. 2, 3
- [5] Yihui He, Rui Yan, Katerina Fragkiadaki, and Shoou-I Yu. Epipolar transformers. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*, pages 7779–7788, 2020. 3
- [6] Catalin Ionescu, Dragos Papava, Vlad Olaru, and Cristian Sminchisescu. Human3.6M: Large scale datasets and predictive methods for 3d human sensing in natural environments. *IEEE Transactions on Pattern Analysis and Machine Intelligence*, 36(7):1325–1339, 2014. 6
- [7] Karim Isakov, Egor Burkov, Victor Lempitsky, and Yury Malkov. Learnable triangulation of human pose. In *Proceedings of the IEEE/CVF International Conference on Computer Vision*, pages 7718–7727, 2019. 1, 3, 6, 7, 8
- [8] Hanbyul Joo, Tomas Simon, Xulong Li, Hao Liu, Lei Tan, Lin Gui, Sean Banerjee, Timothy Godisart, Bart Nabbe, Iain Matthews, Takeo Kanade, Shohei Nobuhara, and Yaser Sheikh. Panoptic studio: A massively multiview system for social interaction capture. *IEEE Transactions on Pattern Analysis and Machine Intelligence*, 41(1):190–204, 2019. 7
- [9] Juho Lee, Yoonho Lee, Jungtaek Kim, Adam R. Kosior, Seungjin Choi, and Yee Whye Teh. Set transformer: A framework for attention-based permutation-invariant neural networks. In *Proceedings of the 36th International Conference on Machine Learning*, pages 3744–3753, 2019. 2, 3
- [10] Ziwei Liao, Jialiang Zhu, Chunyu Wang, Han Hu, and Steven L. Waslander. Multiple view geometry transformers for 3d human pose estimation. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*, pages 708–717, 2024. 1, 2, 3
- [11] Olivier Moliner, Sangxia Huang, and Kalle Åström. Geometry-biased transformer for robust multi-view 3d human pose reconstruction. In *IEEE International Conference on Automatic Face and Gesture Recognition*, pages 1–8, 2024. 1, 3, 6, 7, 8
- [12] Haibo Qiu, Chunyu Wang, Jingdong Wang, Naiyan Wang, and Wenjun Zeng. Cross view fusion for 3d human pose estimation. In *Proceedings of the IEEE/CVF International Conference on Computer Vision*, pages 4342–4351, 2019. 3
- [13] Ke Sun, Bin Xiao, Dong Liu, and Jingdong Wang. Deep high-resolution representation learning for human pose estimation. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*, pages 5693–5703, 2019. 7
- [14] Jinlu Zhang, Zhigang Tu, Jianyu Yang, Yujin Chen, and Junsong Yuan. MixSTE: Seq2seq mixed spatio-temporal encoder for 3d human pose estimation in video. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*, pages 13232–13242, 2022. 2, 3
- [15] Zhe Zhang, Chunyu Wang, Wenhui Qin, and Wenjun Zeng. AdaFuse: Adaptive multiview fusion for accurate human pose estimation in the wild. *International Journal of Computer Vision*, 129:703–718, 2021. 7, 8
- [16] Ce Zheng, Sijie Zhu, Matias Mendieta, Taojiannan Yang, Chen Chen, and Zhengming Ding. 3d human pose estimation with spatial and temporal transformers. In *Proceedings of the IEEE/CVF International Conference on Computer Vision*, pages 11656–11665, 2021. 3